

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Departamento de Ciencias de la Computación

Laboratorio 2

Predicción de visitantes internacionales

Informe explicado para público general

Curso: CC3084 - Data Science, sección 11

Docente: García Pérez, Lynette

Integrantes: Jorge Gabriel Palacios Sales
Pablo Daniel Barillas Moreno
Roberto Emiliano Otoniel Camposeco Torres

Datos: Ingresos mensuales de visitantes a Guatemala, enero de 2009 a junio de 2026

Guatemala, julio de 2026

¿De qué trata este trabajo?

Cada mes, miles de personas cruzan las fronteras de Guatemala como turistas o excursionistas. Este laboratorio buscó responder una pregunta práctica: **¿se puede anticipar, con base en el historial, cuántos visitantes llegarán en los próximos meses?** Contar con una respuesta razonable ayuda a planear personal en fronteras y aeropuertos, coordinar transporte, dimensionar la promoción turística y anticipar la capacidad de atención necesaria.

Para responder, se trabajó con una base de **161,036 registros** que cubre **210 meses seguidos**, de enero de 2009 a junio de 2020, sin huecos ni valores imposibles en la variable principal.

¿Qué personas se contabilizan?

La base distingue dos tipos de visitante, y ambos se sumaron para este análisis:

- **Turistas:** se quedan en el país al menos una noche.
- **Excursionistas:** entran y salen el mismo día.

Las demás categorías se dejaron fuera para conservar exactamente la misma definición utilizada en el Laboratorio 1. De esta manera, la comparación entre los modelos tradicionales y las LSTM se realiza sobre las mismas personas y los mismos meses.

Las dos series que se pronosticaron

Total nacional	La suma de todos los turistas y excursionistas que ingresaron por cualquier frontera del país en cada mes.
01 La Aurora	Solamente quienes llegaron por el principal aeropuerto internacional.

Regla que se respetó en todo el trabajo. Ningún modelo tuvo acceso a información del futuro. Para estimar un mes determinado, únicamente se usó lo ocurrido antes de ese mes.


Un quiebre que marcó la serie

La pandemia interrumpió los viajes de forma abrupta durante 2020 y 2021, y eso dejó una cicatriz difícil de modelar: no existía en el historial ningún cierre de magnitud comparable del cual aprender, así que los modelos tuvieron que enfrentar un tramo sin precedente directo.

¿Cómo se aseguró una prueba justa?

Los 210 meses se respetaron en su orden cronológico; en ningún momento se usaron meses futuros para “adivinar” meses pasados.

- **Entrenamiento:** 147 meses, de enero de 2009 a marzo de 2021.
- **Prueba final:** 63 meses, de abril de 2021 a junio de 2026.



Dentro de los 147 meses de entrenamiento se apartó, además, un tramo interno para decidir cuál configuración de modelo convenía usar. La comparación es similar a resolver guías de práctica antes del examen: esas guías permiten ajustar la estrategia, pero las respuestas del examen final se mantienen guardadas hasta el final.

¿Qué es una “ventana” de meses?

Antes de estimar un mes, el modelo revisa una cantidad fija de meses previos. Se probaron dos tamaños de ventana:

- 12 meses (un año de historia reciente).
- 24 meses (dos años de historia reciente).

¿Con qué se midió el acierto?

Se calcularon tres indicadores de error, y el más usado para decidir entre modelos fue el RMSE.

- **MAE:** el error promedio, expresado directamente en número de visitantes.
- **RMSE:** parecido al MAE, pero castiga con más fuerza los errores grandes.
- **sMAPE:** expresa el error como porcentaje, lo que permite comparar series de tamaños distintos entre sí.

Regla de lectura. En los tres indicadores anteriores aplica lo mismo: **mientras más bajo el número, más cerca estuvo el modelo de lo que realmente ocurrió.**

¿Qué es una LSTM y cómo se eligió una?

Una LSTM es una técnica pensada para aprender de datos que llegan en orden, como los meses de una serie de tiempo. Puede pensarse como una memoria que, mes a mes, resuelve tres preguntas:

1. ¿qué información pasada vale la pena conservar?
2. ¿qué información reciente conviene incorporar?
3. ¿qué parte de todo lo anterior se usa para calcular la siguiente estimación?


Nadie le indicó a mano cuánto debía subir o bajar la cifra cada mes: el propio método ajustó sus parámetros internos revisando muchos ejemplos históricos.

No se apostó a una sola configuración

Para no depender de una única receta, se entrenaron y compararon cuatro variantes de LSTM por cada serie:

Modelo	Estructura	Meses observados	Tamaño interno
LSTM-1A	Una capa de memoria	12	8
LSTM-1B	Una capa de memoria	24	16
LSTM-2A	Dos capas de memoria	12	12 y 6
LSTM-2B	Dos capas de memoria	24	16 y 8

Además, se documentaron dos diseños de mayor tamaño que se probaron en ambas series y luego se descartaron por su menor estabilidad. Por ello, la elección final no se basó solamente en la cifra más baja de una prueba aislada.




Los candidatos que quedaron mejor posicionados

- Para el **total nacional**, la variante ganadora fue LSTM-1A.
- Para **La Aurora**, la variante ganadora fue LSTM-2A.

Vale la pena notar que la red más grande no fue la mejor en ambos casos. Eso confirma algo importante: agregar más complejidad no garantiza más precisión. Cuando la cantidad de datos disponibles es limitada, una estructura más sencilla puede generalizar mejor que una elaborada.

El resultado que más importa: la comparación final

Los dos modelos ganadores se volvieron a entrenar, esta vez con los 147 meses completos, y produjeron un pronóstico mes a mes para los 63 meses de prueba que nunca habían visto. Ese pronóstico se comparó contra los mejores modelos tradicionales obtenidos en el Laboratorio 1.



Serie	RMSE LSTM	RMSE anterior	Mejora
01 La Aurora	31,020	42,053	26.24%
Total nacional	137,339	139,549	1.58%

Cómo interpretar esta tabla


La Aurora. Aquí la LSTM sí marcó una diferencia clara: su error grande típico (RMSE) bajó cerca de una cuarta parte frente al método anterior, llamado SES.

Total nacional. La LSTM también quedó por encima de Prophet, pero por un margen pequeño, de apenas 1.58%. En la práctica, esto quiere decir que ambos métodos tuvieron un desempeño bastante parejo, y que descartar Prophet por completo no estaría justificado.

Una conclusión con matices. La LSTM ganó en estas dos comparaciones puntuales, pero eso no debe leerse como que siempre será la mejor opción para cualquier otra frontera, país o período de tiempo.

Que ambas series se comporten distinto tiene sentido: La Aurora es un único punto de entrada, mientras que el total nacional mezcla pasos aéreos, terrestres y marítimos, cada uno con su propia dinámica.

¿Cómo se ven los pronósticos en la práctica?



En la gráfica, la línea sólida es lo que realmente ocurrió y la línea punteada es lo que el modelo LSTM estimó para ese mismo período.

Total nacional

El modelo capta bien la recuperación gradual después de la pandemia, pero luego tiende a “aplanarse” más de lo debido: no reproduce cada subida y bajada mensual. Esto explica por qué su ventaja frente a Prophet fue pequeña y por qué su error porcentual se mantuvo relativamente alto.

La Aurora

Aquí el pronóstico sigue con más fidelidad el nivel general de visitantes tras la reapertura de fronteras. No acierta cada pico puntual, pero su trayectoria general queda más cerca de los datos reales, lo cual coincide con la mejora más marcada que obtuvo frente a SES.

¿Por qué el modelo no acierta cada mes exacto?

- El cierre de 2020 fue un evento extraordinario, sin un antecedente parecido en el historial disponible.
- El modelo no recibió información sobre vuelos, feriados, restricciones migratorias, economía o tipo de cambio.
- El horizonte de pronóstico supera los cinco años, y en horizontes así de largos los pequeños errores se van acumulando mes tras mes.

Cómo usar estos pronósticos. Son una herramienta de apoyo para planificar, no una cifra exacta garantizada. Siempre deben revisarse junto con información actualizada del contexto.

catch22: una forma de “huella digital” para cada serie


Más allá de pronosticar, también interesaba entender qué series se comportan de manera parecida entre sí. Para eso se recurrió a una técnica llamada *catch22*.

La idea es sencilla de imaginar: cada serie recibe una **huella digital de 22 números**, donde cada número resume un aspecto distinto de su comportamiento en el tiempo, por ejemplo:

- qué tanto se repiten o dependen los valores entre meses cercanos;
- si existen ciclos o patrones estacionales;
- si hay meses inusualmente altos o bajos;
- qué tan rápido o lento cambia la serie;
- qué tan estables o volátiles son sus fluctuaciones.

Se calculó esta huella para siete series distintas:

- el total nacional;
- las regiones América Del Centro, América Del Norte y Europa;
- las fronteras La Aurora, Valle Nuevo y San Cristóbal.




En este mapa de calor, los colores rojo y azul no significan “bueno” o “malo”; simplemente muestran si una característica está por encima o por debajo del promedio de las siete series analizadas.

¿Para qué sirve esto? Dos series pueden tener cantidades muy distintas de visitantes y, aun así, moverse con una forma parecida en el tiempo. *catch22* permite comparar esa forma, independientemente de la escala de cada serie.

¿Qué series terminaron pareciéndose más?

Las 22 características de cada serie se resumieron en un mapa de dos dimensiones. En ese mapa, los puntos que quedan más cerca representan series con comportamientos más similares.



Los hallazgos más relevantes

- **El par más parecido** fue el total nacional con América Del Centro.
- **La serie más distinta** de todas resultó ser 01 La Aurora.
- **Grupo 1:** total nacional, América Del Centro, Valle Nuevo y San Cristóbal.
- **Grupo 2:** América Del Norte y Europa.
- **Grupo 3:** La Aurora, sola, sin acompañamiento cercano.

Que el total nacional quede cerca de América Del Centro es coherente con el peso que tienen los mercados centroamericanos y las fronteras terrestres. La Aurora, en cambio, se aparta del resto porque depende directamente de los vuelos internacionales y vivió una caída y una recuperación con un ritmo muy particular.


Un hallazgo que vale la pena resaltar

Pertenecer a la misma categoría administrativa no garantiza un comportamiento parecido. La Aurora, Valle Nuevo y San Cristóbal son todas fronteras, pero La Aurora no terminó agrupada con las otras dos. Esto sugiere que la forma en que cambia una serie a lo largo del tiempo puede decir más sobre ella que la simple etiqueta que se le asigne.

Este análisis se hizo con solo siete series, así que los grupos encontrados deben tomarse como una guía exploratoria y no como una clasificación definitiva de todas las fronteras o mercados del país.

¿Ayudó agregar catch22 a mejorar el pronóstico?

Se construyó un modelo adicional, esta vez para La Aurora, que además de observar los últimos 12 meses también recibía la huella catch22 calculada con los 36 meses previos.



Modelo	MAE	RMSE
LSTM base	24,473	31,020
SES	36,822	42,053
LSTM con catch22	34,356	42,907

El resultado no fue el esperado, pero sí fue informativo

Agregar catch22 **no mejoró** el pronóstico: su RMSE (42,907) quedó por encima del de la LSTM base (31,020). En otras palabras, la versión más compleja no resultó más precisa.

Algunas razones probables:

- había pocos ejemplos disponibles para que el modelo aprendiera a usar 23 entradas simultáneas en lugar de solo una;
- varias de las 22 características resultaron redundantes entre sí;
- una huella pensada para *comparar* series completas no necesariamente aporta valor para *pronosticar* mes a mes.

Por qué este resultado importa igual. Confirmar que algo no funciona también es un aprendizaje válido: evita invertir esfuerzo en una solución más complicada cuando la alternativa sencilla ya rinde mejor.

Conclusiones y recomendaciones

Lo que se puede afirmar con los datos disponibles

1. Se trabajó con 210 meses completos de dos series de visitantes.
2. Se compararon cuatro variantes finales de LSTM por cada serie y se documentaron dos diseños adicionales que fueron descartados.
3. La LSTM redujo el error en La Aurora en 26.24% frente a SES.
4. En el total nacional, la mejora frente a Prophet fue de 1.58%.
5. El total nacional y América Del Centro resultaron ser las series más parecidas entre sí.
6. La Aurora fue, de las siete series analizadas, la de comportamiento más particular.
7. Sumar catch22 a la LSTM no mejoró la calidad del pronóstico.

Recomendaciones para usar esto en la práctica

- Reentrenar los modelos cada vez que se incorporen meses nuevos a la base.
- Conservar más de un método disponible; no depender de un único algoritmo.
- Separar los pronósticos por frontera o región cuando se necesite planificar recursos a nivel local.
- Explorar la incorporación de vuelos, feriados, restricciones y variables económicas como información adicional.
- Comunicar los resultados como rangos o escenarios, no como una única cifra exacta.
- Dejar constancia de cualquier cambio futuro en la forma de registrar visitantes, para no romper la comparabilidad histórica.

Glosario mínimo

LSTM	Técnica que aprende patrones en datos ordenados en el tiempo y conserva memoria de meses anteriores.
Pronóstico	Estimación de un valor que todavía no se conoce.
RMSE	Medida de error que penaliza con más fuerza las equivocaciones grandes.
catch22	Conjunto de 22 números que resume la forma temporal de una serie.
PCA	Mapa simplificado que permite observar semejanzas entre muchas características a la vez.
Clustering	Procedimiento que agrupa elementos con comportamientos parecidos.