

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Departamento de Ciencias de la Computación

Laboratorio 2

Deep Learning para Series de Tiempo

Informe técnico y análisis reproducible

Curso:	CC3084 - Data Science
Docente:	García Pérez, Lynette
Sección:	11
Integrantes:	Jorge Gabriel Palacios Sales Pablo Daniel Barillas Moreno Roberto Emiliano Otoniel Camposeco Torres
Fuente:	Base_Migracion_2009-2026jun.xlsx
Período:	Enero de 2009 a junio de 2026

Guatemala, julio de 2026

Contenido

1	Resumen	1
2	Objetivos	2
2.1	Objetivo general	2
2.2	Objetivos específicos	2
3	Descripción y preparación de los datos	2
3.1	Fuente y estructura	2
3.2	Definición de visitante	3
3.3	Series seleccionadas	3
4	Diseño del experimento	4
4.1	Partición externa e interna	4
4.2	Ventanas supervisadas	5
5	Fundamento del modelo LSTM	5
5.1	Motivación	5
5.2	Ecuaciones	5
5.3	Implementación reproducible	5
6	Tuneo de hiperparámetros	6
6.1	Espacio de búsqueda	6
6.2	Métricas	6
6.3	Resultados de validación	6
6.4	Configuraciones descartadas	8
7	Pronóstico definitivo y comparación	9
7.1	Reentrenamiento	9
7.2	Comparación con modelos tradicionales	10
8	Extracción de características catch22	10
8.1	Concepto	10
8.2	Preprocesamiento	11
8.3	Diccionario de características	11
9	Análisis multivariado de catch22	12

9.1	Análisis de Componentes Principales	12
9.2	Clustering jerárquico	13
9.3	Distancias entre series	14
9.4	Correlaciones entre características	15
10	Interpretación de los incisos 2.7 a 2.13	16
10.1	Series más similares	16
10.2	Características más importantes	16
10.3	Grupos naturales	16
10.4	Categoría y agrupamiento	16
10.5	Comportamiento atípico	16
10.6	Consistencia con el análisis anterior	16
10.7	Tres descubrimientos adicionales	17
11	Modelo LSTM enriquecido con catch22	17
11.1	Diseño	17
11.2	Resultados	17
12	Conclusiones	18
13	Limitaciones y recomendaciones	19
14	Verificación de cumplimiento	19
	Referencias	20

Lista de figuras

1	Series mensuales utilizadas para el modelado LSTM.	3
2	Partición cronológica de ajuste, validación y prueba.	4
3	RMSE de validación de las configuraciones LSTM.	7
4	Curvas de pérdida y época seleccionada.	7
5	Predicción de un paso en el tramo de validación.	8
6	Pronóstico recursivo de abril de 2021 a junio de 2026.	9
7	Comparación de RMSE en el mismo conjunto de prueba.	10
8	Matriz estandarizada de características catch22.	12
9	Proyección de las siete series sobre los dos primeros componentes.	12
10	Dendrograma del clustering jerárquico Ward.	13
11	Distancias euclídeas entre perfiles catch22 estandarizados.	14
12	Correlaciones observadas entre las 22 características.	15
13	Predicción base y predicción enriquecida para La Aurora.	18

Lista de tablas

1	Controles generales de la base	2
2	Configuraciones LSTM evaluadas en cada serie	6
3	Resultados del tuneo interno	6
4	Configuraciones descartadas y su desempeño en validación	8
5	Resultados LSTM sobre el conjunto de prueba	9
6	LSTM frente al mejor método del Laboratorio 1	10
7	Características catch22 utilizadas	11
8	Asignación de grupos con clustering Ward	13
9	Comparación del modelo enriquecido en La Aurora	17
10	Correspondencia con las instrucciones del laboratorio	19

1 Resumen

Este laboratorio estudia si las redes Long Short-Term Memory (LSTM) pueden pronosticar dos series mensuales de visitantes internacionales y si su desempeño supera a los modelos tradicionales ajustados en el Laboratorio 1. Adicionalmente, se utiliza el conjunto de características *catch22* para comparar siete series desde múltiples perspectivas temporales.

La base contiene 161,036 registros y 210 meses consecutivos, desde enero de 2009 hasta junio de 2026. Para conservar comparabilidad histórica se define visitante como la suma de *Turista* y *Excursionista*. Las dos series empleadas para el pronóstico son el total nacional y la frontera 01 La Aurora. Se mantienen los primeros 147 meses como entrenamiento y los últimos 63 meses como prueba.

Se evaluaron cuatro configuraciones LSTM por serie. Después del tuneo cronológico, LSTM-1A fue seleccionada para el total nacional y LSTM-2A para La Aurora. En prueba, la LSTM del total obtuvo RMSE de 137,339, una mejora de 1.58% respecto a Prophet. Para La Aurora se obtuvo RMSE de 31,020, una mejora de 26.24% frente a suavizamiento exponencial simple.

El análisis *catch22* produjo una matriz de siete series por 22 características. El total nacional y América Del Centro fueron el par más similar, mientras La Aurora fue la serie más atípica. Finalmente, un modelo LSTM enriquecido con características *catch22* no superó a la LSTM base: su RMSE fue 42,907. Este resultado muestra que una representación útil para describir y agrupar series no necesariamente mejora el pronóstico.

Hallazgo central. Las LSTM superaron a los mejores modelos del Laboratorio 1 en ambas series. La mejora fue pequeña en el total nacional, pero sustancial en La Aurora. El uso adicional de *catch22* dentro de la red no produjo una mejora predictiva.

2 Objetivos

2.1 Objetivo general

Construir, ajustar y evaluar modelos LSTM para dos series mensuales de visitantes internacionales, comparar sus resultados con métodos tradicionales y explorar la similitud de todas las series mediante *catch22*.

2.2 Objetivos específicos

1. Reproducir las dos series y la partición temporal del Laboratorio 1.
2. Evaluar al menos dos configuraciones LSTM por cada serie.
3. Seleccionar hiperparámetros sin utilizar información del test.
4. Pronosticar los 63 meses reservados y calcular MAE, RMSE, NRMSE y sMAPE.
5. Comparar los ganadores LSTM con Prophet y SES.
6. Extraer 22 características *catch22* para siete series.
7. Estandarizar las características y aplicar PCA, clustering, mapas de calor, correlaciones y distancias.
8. Interpretar los grupos, similitudes y comportamientos atípicos.
9. Construir una LSTM enriquecida con características *catch22* y contrastarla con la LSTM base.

3 Descripción y preparación de los datos

3.1 Fuente y estructura

La hoja **Datos** se encuentra en formato largo. Cada fila representa una combinación de año, mes, vía, frontera, país o agrupación, región y tipo de viajero. La columna cuantitativa **Viajero** indica el número de personas correspondiente a esa combinación.

Tabla 1: Controles generales de la base

Indicador	Resultado
Registros	161,036
Meses únicos	210
Fecha inicial	Enero de 2009
Fecha final	Junio de 2026
Faltantes en la medida	0
Valores negativos	0
Frecuencia	Mensual

3.2 Definición de visitante

La base distingue turistas, excursionistas, viajeros y cruceristas. Se utilizan exclusivamente turistas y excursionistas:

$$Y_t = \sum_{i \in \{\text{Turista}, \text{Excursionista}\}} \text{Viajero}_{i,t}.$$

Las demás categorías se excluyen para reproducir exactamente la definición de serie empleada en el Laboratorio 1. Esta decisión mantiene constante el universo de personas, la cobertura temporal y la base de comparación con los modelos tradicionales.

3.3 Series seleccionadas

Para el ejercicio LSTM se utilizan:

- **Total nacional:** suma mensual en todas las fronteras.
- **01 La Aurora:** suma mensual correspondiente a la principal frontera aérea.

Para el análisis *catch22* se agregan las tres regiones y las tres fronteras con mayor acumulado:

- Regiones: América Del Centro, América Del Norte y Europa.
- Fronteras: 01 La Aurora, 07 Valle Nuevo y 09 San Cristóbal.




Figura 1: Series mensuales utilizadas para el modelado LSTM.

Ambas series exhiben crecimiento antes de 2020, estacionalidad anual, un colapso extraordinario durante la pandemia y una recuperación posterior. La ruptura de 2020 dificulta el aprendizaje porque no existe un evento equivalente en los años previos.

4 Diseño del experimento

4.1 Partición externa e interna

La separación reproduce el Laboratorio 1:

$$n_{\text{train}} = \lfloor 0.70(210) \rfloor = 147, \quad n_{\text{test}} = 63.$$

El entrenamiento abarca enero de 2009 a marzo de 2021 y la prueba abril de 2021 a junio de 2026. Dentro de los 147 meses se define un tramo interno de 117 meses para ajustar pesos y 30 meses para validar hiperparámetros.




Figura 2: Partición cronológica de ajuste, validación y prueba.

No se barajan las fechas. El escalador Min-Max se ajusta solo con el tramo interno de entrenamiento durante el tuneo y con los 147 meses completos durante el reentrenamiento final. El test no se utiliza para seleccionar arquitecturas, épocas o parámetros.

4.2 Ventanas supervisadas

Para una ventana de longitud w , la entrada y el objetivo son:

$$(y_{t-w}, \dots, y_{t-1}) \longrightarrow y_t.$$

Se evalúan ventanas de 12 y 24 meses. La primera contiene un ciclo anual y la segunda dos ciclos completos. La predicción final es recursiva: cada valor pronosticado se incorpora al historial temporal para producir el siguiente.

5 Fundamento del modelo LSTM

5.1 Motivación

Las redes recurrentes procesan datos ordenados y mantienen un estado interno. Una LSTM agrega puertas que regulan qué información debe conservarse, actualizarse u olvidarse. Esto reduce el problema de gradientes que se desvanecen en secuencias largas.

5.2 Ecuaciones

Para la entrada x_t , el estado oculto previo h_{t-1} y la memoria c_{t-1} , la celda utilizada calcula:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f), \quad (1)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i), \quad (2)$$

$$\tilde{c}_t = \tanh(W_g[h_{t-1}, x_t] + b_g), \quad (3)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad (4)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o), \quad (5)$$

$$h_t = o_t \odot \tanh(c_t). \quad (6)$$

La salida final se obtiene mediante una transformación lineal del último estado oculto. Los pesos se optimizan con Adam. Se aplica regularización L2, recorte global del gradiente y parada temprana.

5.3 Implementación reproducible

La LSTM fue implementada explícitamente en NumPy. La implementación incluye las cuatro puertas, retropropagación a través del tiempo, una o dos capas, Adam, semillas deterministas y control de gradiente. Además, se comprobó la derivada mediante diferencias finitas, con error relativo inferior a 10^{-7} .

6 Tuneo de hiperparámetros

6.1 Espacio de búsqueda

Tabla 2: Configuraciones LSTM evaluadas en cada serie

Modelo	Capas	Ventana	Unidades	Tasa	L2	Lote
LSTM-1A	Una	12	8	0.010	0.0001	16
LSTM-1B	Una	24	16	0.006	0.0003	16
LSTM-2A	Dos	12	12, 6	0.006	0.0001	16
LSTM-2B	Dos	24	16, 8	0.004	0.0003	16

Se utilizan como máximo 90 épocas, paciencia de 12 épocas y norma máxima del gradiente de 5. El ganador se define por el menor RMSE de validación en la escala original de visitantes.

6.2 Métricas

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|, \quad (7)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}, \quad (8)$$

$$\text{sMAPE} = \frac{100}{n} \sum_{t=1}^n \frac{2|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|}. \quad (9)$$

RMSE es el criterio principal porque penaliza con mayor fuerza los errores grandes. MAE expresa el error mensual típico y sMAPE permite comparar series de escalas diferentes.

6.3 Resultados de validación

Tabla 3: Resultados del tuneo interno

Serie	Modelo	MAE	RMSE	sMAPE
La Aurora	LSTM-2A	38,271	52,041	63.21%
La Aurora	LSTM-1B	39,500	52,843	64.22%
La Aurora	LSTM-2B	46,354	55,376	71.23%
La Aurora	LSTM-1A	50,891	60,566	74.48%
Total nacional	LSTM-1A	94,593	121,318	64.78%
Total nacional	LSTM-1B	94,530	128,869	62.60%
Total nacional	LSTM-2B	106,658	134,268	68.60%
Total nacional	LSTM-2A	104,326	137,687	66.05%




Figura 3: RMSE de validación de las configuraciones LSTM.

Los ganadores provisionales son LSTM-2A para La Aurora y LSTM-1A para el total. Una arquitectura más profunda no garantiza mejor resultado: el total nacional favorece la red de una sola capa y ocho unidades.




Figura 4: Curvas de pérdida y época seleccionada.

La diferencia entre ajuste y validación se explica principalmente por el cambio de régimen. La validación incluye marzo de 2020 a marzo de 2021. Para La Aurora, el RMSE durante el choque fue 3.9 veces el error previo; para el total fue 3.0 veces.




Figura 5: Predicción de un paso en el tramo de validación.

6.4 Configuraciones descartadas

La rejilla de la Tabla 2 es reducida a propósito. Se llegó a ese tamaño después de evaluar redes más grandes y ventanas más largas, cuyos resultados se documentan aquí porque explican la decisión mejor que un párrafo aislado.

Tabla 4: Configuraciones descartadas y su desempeño en validación

Serie	Modelo	RMSE	MAE	Época	Ventana / unidades
Total nacional	LSTM-1X (descartada)	138,590	105,215	1/13	12 / 64
Total nacional	LSTM-2X (descartada)	119,488	98,475	32/44	36 / 32, 16
La Aurora	LSTM-1X (descartada)	52,938	37,124	1/13	12 / 64
La Aurora	LSTM-2X (descartada)	58,512	48,810	17/29	36 / 32, 16

Los dos casos fallan por caminos distintos. La red de 64 unidades (LSTM-1X) se detiene en la época 1 con una brecha entre pérdida de ajuste y de validación de 7.6 veces (0.141 contra 1.066 en el total nacional): memoriza los 105 ejemplos de ajuste antes de alcanzar a aprender la estacionalidad. La configuración de ventana 36 sin regularización L2 (LSTM-2X) llega a una brecha de 15.5 veces (0.051 contra 0.792), la mayor de todas las configuraciones probadas.

Precaución metodológica. En el total nacional, LSTM-2X obtuvo un RMSE de validación menor que el ganador finalmente seleccionado: 119,488 contra 121,318 de LSTM-1A, una diferencia de 1.5%. No se incorporó a la rejilla final ni se eligió como ganadora por tres razones: (1) la ventana de 36 meses reduce los ejemplos de ajuste de 105 a 81 y sacrifica los primeros tres años de la serie; (2) la ventaja no se sostiene en la otra serie, donde LSTM-2X queda 12.4% por debajo de LSTM-2A en La Aurora (58,512 contra 52,041); y (3) es la configuración con la mayor brecha entre ajuste y validación, por lo que una diferencia de 1.5% en una sola serie no constituye evidencia suficiente. Se prefirió aplicar un criterio único a ambas series antes que escoger la mejor cifra de cada tabla por separado.

7 Pronóstico definitivo y comparación

7.1 Reentrenamiento

Cada ganador se inicializa nuevamente y se ajusta con los 147 meses completos. Se utiliza el número de épocas obtenido en la validación: cuatro para LSTM-1A del total y una para LSTM-2A de La Aurora.

Tabla 5: Resultados LSTM sobre el conjunto de prueba

Serie	MAE	RMSE	NRMSE	sMAPE
01 La Aurora	24,473	31,020	32.97%	28.15%
Total nacional	123,954	137,339	56.84%	63.35%




Figura 6: Pronóstico recursivo de abril de 2021 a junio de 2026.

La predicción de La Aurora reproduce mejor el nivel general de la recuperación. En el total nacional, la trayectoria converge a una banda relativamente estable y no representa completamente los picos mensuales. Esto explica su NRMSE de 56.84%.

7.2 Comparación con modelos tradicionales

Los valores de referencia provienen del notebook ejecutado del Laboratorio 1. Prophet había ganado para el total nacional y SES para La Aurora.

Tabla 6: LSTM frente al mejor método del Laboratorio 1

Serie	Comparación	RMSE LSTM	RMSE anterior	Mejora
01 La Aurora	LSTM-2A vs. SES	31,020	42,053	26.24%
Total nacional	LSTM-1A vs. Prophet	137,339	139,549	1.58%




Figura 7: Comparación de RMSE en el mismo conjunto de prueba.

Respuesta al Ejercicio 1.4. La LSTM predijo mejor en ambas series según RMSE. La mejora de La Aurora es clara y alcanza 26.24%. En el total nacional la diferencia es de 1.58%, por lo que debe interpretarse como una ventaja pequeña y no como superioridad universal.

8 Extracción de características catch22

8.1 Concepto

catch22 es un conjunto canónico de 22 características seleccionadas para resumir propiedades de una serie temporal. Incluye medidas relacionadas con distribución, autocorrelación, periodicidad, información mutua, comportamiento simbólico, valores atípicos, contenido espectral y fluctuaciones de largo alcance.

El método permite representar cada serie como un vector de igual longitud. Así, series con escalas distintas pueden compararse mediante distancias, proyecciones o agrupamientos.

8.2 Preprocesamiento

Cada serie se normaliza primero con media cero y desviación estándar uno. Se extraen las 22 características mediante `pycatch22 0.4.5`. La matriz resultante tiene siete filas y 22 columnas. Luego cada característica se estandariza entre las siete series:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Esta segunda estandarización evita que una característica con rango amplio domine PCA, clustering y distancias.

8.3 Diccionario de características

Tabla 7: Características catch22 utilizadas

Alias	Nombre oficial	Interpretación breve
F01	DN_HistogramMode_5	Moda aproximada con cinco intervalos.
F02	DN_HistogramMode_10	Moda aproximada con diez intervalos.
F03	CO_flecac	Primer cruce de autocorrelación bajo $1/e$.
F04	CO_FirstMin_ac	Primer mínimo de autocorrelación.
F05	CO_HistogramAMI_even_2_5	Información mutua con retardo dos.
F06	CO_trev_1_num	Asimetría temporal de cambios sucesivos.
F07	MD_hrv_classic_pnn40	Proporción de cambios consecutivos grandes.
F08	SB_BinaryStats_mean_longstretch1	Racha más larga sobre la media.
F09	SB_TransitionMatrix_3ac_sumdiagcov	Persistencia de estados simbólicos.
F10	PD_PeriodicityWang_th0_01	Longitud del patrón periódico dominante.
F11	CO_Embed2_Dist_tau_d_expfit_meandiff	Estructura geométrica de retardos.
F12	IN_AutoMutualInfoStats_40_gaussian_fmfi	Primer mínimo de información mutua.
F13	FC_LocalSimple_mean1_ttauresrat	Dependencia residual tras predictor local.
F14	DN_OutlierInclude_p_001_mdrmd	Distribución temporal de atípicos positivos.
F15	DN_OutlierInclude_n_001_mdrmd	Distribución temporal de atípicos negativos.
F16	SP_Summaries_welch_rect_area_5_1	Potencia relativa de baja frecuencia.
F17	SB_BinaryStats_diff_longstretch0	Racha de disminuciones consecutivas.
F18	SB_MotifThree_quantile_hh	Entropía de motivos de tres símbolos.
F19	SC_FluctAnal_2_rsrangefit_50_1_logi_prop_r1	Escala de fluctuación por rango reescalado.
F20	SC_FluctAnal_2_dfa_50_1_2_logi_prop_r1	Escala de fluctuación mediante DFA.
F21	SP_Summaries_welch_rect_centroid	Centroide espectral.
F22	FC_LocalSimple_mean3_stderr	Error de predictor local de tres puntos.




Figura 8: Matriz estandarizada de características catch22.

9 Análisis multivariado de catch22

9.1 Análisis de Componentes Principales

PCA transforma las 22 características correlacionadas en ejes ortogonales. PC1 explica 33.90% de la variación y PC2 29.14%; en conjunto representan 63.04%.




Figura 9: Proyección de las siete series sobre los dos primeros componentes.

El total nacional y América Del Centro aparecen muy próximos. América Del Norte y Europa ocupan el lado positivo de PC1. La Aurora se separa principalmente sobre PC2 y constituye el punto más aislado.

Las características con mayor carga conjunta son F01, F20, F13, F14, F22, F08, F16 y F18. Por tanto, la separación depende de la forma de la distribución, persistencia, predicción local, atípicos positivos, potencia de baja frecuencia y estructura simbólica.

9.2 Clustering jerárquico

Se compararon dos, tres y cuatro grupos. Los puntajes de silueta fueron 0.207, 0.247 y 0.253, respectivamente. Aunque cuatro grupos produce una diferencia ligeramente mayor, se seleccionan tres para evitar una fragmentación excesiva de solo siete observaciones.

Tabla 8: Asignación de grupos con clustering Ward

Grupo	Series
1	Total nacional; América Del Centro; Valle Nuevo; San Cristóbal
2	América Del Norte; Europa
3	01 La Aurora



Figura 10: Dendrograma del clustering jerárquico Ward.

El grupo 1 combina el agregado nacional con una región y dos fronteras terrestres. El grupo 2 contiene dos regiones con perfiles temporales semejantes. La Aurora forma un grupo propio, lo cual evidencia que las categorías administrativas no determinan por sí solas la similitud temporal.

9.3 Distancias entre series




Figura 11: Distancias euclídeas entre perfiles catch22 estandarizados.

El par más cercano es total nacional y América Del Centro, con distancia 2.667. Después aparecen América Del Centro con Valle Nuevo (3.440) y total nacional con Valle Nuevo (3.969). El par más distante es América Del Norte y La Aurora (9.111).

9.4 Correlaciones entre características




Figura 12: Correlaciones observadas entre las 22 características.

Existen correlaciones altas entre varios descriptores porque algunos resumen formas relacionadas de persistencia, fluctuación o dependencia. Con solo siete series, estas correlaciones son exploratorias y no deben generalizarse como relaciones universales.

Precaución metodológica. El número de variables es mayor que el número de series. PCA, correlaciones y clustering sirven para explorar esta colección concreta, pero no constituyen una clasificación definitiva de toda la actividad migratoria.

10 Interpretación de los incisos 2.7 a 2.13

10.1 Series más similares

El total nacional y América Del Centro son las más similares según distancia, PCA y clustering. La explicación contextual es que Centroamérica aporta un componente importante del total y se relaciona con las principales entradas terrestres.

10.2 Características más importantes

Las cargas de PCA identifican como relevantes la moda de la distribución, fluctuaciones de largo alcance, capacidad de predicción local, atípicos positivos, rachas sobre la media, potencia de baja frecuencia y motivos simbólicos. Estas variables capturan diferencias que una comparación basada solo en promedios no detectaría.

10.3 Grupos naturales

Se observan tres grupos interpretables. El primero refleja la dinámica centroamericana y terrestre; el segundo reúne Norteamérica y Europa; el tercero contiene únicamente La Aurora. El puntaje de silueta es modesto, por lo que los límites entre grupos no son absolutos.

10.4 Categoría y agrupamiento

Las series de una misma categoría no siempre se agrupan. Valle Nuevo y San Cristóbal se acercan al total y a América Del Centro, mientras La Aurora se separa. Del mismo modo, América Del Centro no queda con las otras dos regiones. La dinámica observada pesa más que la etiqueta administrativa.

10.5 Comportamiento atípico

La Aurora posee la mayor distancia al centroide, 6.053. Su comportamiento aéreo, el cierre de vuelos, la reapertura y un patrón estacional propio explican esta posición. Europa y América Del Norte también muestran perfiles alejados, pero no superan el aislamiento de La Aurora.

10.6 Consistencia con el análisis anterior

- **Tendencia:** total y América Del Centro conservan trayectorias similares antes de 2020.
- **Estacionalidad:** periodicidad y componentes espectrales recuperan diferencias observadas en perfiles mensuales.
- **Volatilidad:** fluctuaciones y error local distinguen series con recuperaciones estables de aquellas con cambios bruscos.
- **Pandemia:** atípicos y persistencia representan la duración y magnitud desigual del choque.
- **Autocorrelación:** F03, F04 y F12 resumen dependencia temporal estudiada previamente mediante ACF.

10.7 Tres descubrimientos adicionales

1. El total se parece más a América Del Centro que a cualquier frontera individual, aunque La Aurora sea la frontera de mayor acumulado.
2. América Del Norte y Europa comparten un perfil temporal multivariado pese a sus diferencias de volumen y procedencia.
3. La categoría frontera no es homogénea: La Aurora se separa, mientras Valle Nuevo y San Cristóbal se integran al bloque centroamericano.

11 Modelo LSTM enriquecido con catch22

11.1 Diseño

Se elige La Aurora porque fue la serie más atípica. El modelo conserva la arquitectura LSTM-2A y una ventana cruda de 12 meses. Para cada objetivo se calculan 22 características utilizando únicamente los 36 meses anteriores. El vector se repite a lo largo de los 12 pasos de entrada:

$$\mathbf{x}_t = \left[y_t, f_{1,t}^{(catch22)}, \dots, f_{22,t}^{(catch22)} \right].$$

La entrada pasa de una a 23 variables por paso. Los descriptores se imputan y estandarizan solo con el entrenamiento. En el test, se recalculan de forma recursiva sobre el historial disponible.

11.2 Resultados

Tabla 9: Comparación del modelo enriquecido en La Aurora

Modelo	MAE	RMSE	sMAPE
LSTM-2A base	24,473	31,020	28.15%
SES	36,822	42,053	45.47%
LSTM-2A + catch22	34,356	42,907	43.58%




Figura 13: Predicción base y predicción enriquecida para La Aurora.

El modelo enriquecido empeora el RMSE en aproximadamente 38.32% respecto a la LSTM base. También queda ligeramente por debajo de SES. El resultado no invalida *catch22*: las características fueron eficaces para comparar series, pero al repetirse en cada paso aumentan la dimensionalidad con pocos ejemplos y pueden introducir redundancia.

Una arquitectura futura podría procesar la secuencia mediante una LSTM y el vector *catch22* mediante una rama densa independiente antes de combinar ambas representaciones.

12 Conclusiones

1. Se ajustaron ocho candidatos de la rejilla final, cuatro por serie, y se documentaron dos diseños adicionales evaluados en ambas series. El tuneo fue cronológico y no utilizó el conjunto de prueba.
2. LSTM-2A fue la mejor configuración para La Aurora y LSTM-1A para el total nacional.
3. En prueba, las LSTM superaron a los ganadores del Laboratorio 1. La mejora fue 26.24% para La Aurora y 1.58% para el total.
4. La matriz *catch22* identificó al total nacional y América Del Centro como el par más similar.
5. La Aurora fue la serie más atípica y formó un grupo propio.
6. Las categorías administrativas no garantizan comportamientos temporales semejantes.
7. Añadir *catch22* directamente a la entrada LSTM no mejoró la predicción. La LSTM base fue más simple y precisa.

13 Limitaciones y recomendaciones

- El test inicia durante la recuperación pandémica y cubre un horizonte largo de 63 meses.
- Los modelos no incluyen vuelos, cierres, feriados, tipo de cambio o actividad económica.
- Solo se estudiaron siete series para el análisis multivariado.
- El mejor modelo debe actualizarse conforme se incorporen meses nuevos.
- Para uso institucional se recomienda comparar periódicamente LSTM, Prophet, suavizamiento y modelos estacionales.
- Las predicciones deben acompañarse con intervalos de incertidumbre y escenarios cuando se utilicen para planificación.

14 Verificación de cumplimiento

Tabla 10: Correspondencia con las instrucciones del laboratorio

Requisito	Estado
Dos series y misma partición del Laboratorio 1	Cumplido
Dos configuraciones LSTM por serie	Cumplido
Tuneo y selección por validación	Cumplido
Pronóstico con el mejor modelo	Cumplido
Comparación entre LSTM y contra modelos anteriores	Cumplido
Extracción de 22 características para siete series	Cumplido
Matriz y estandarización	Cumplido
PCA, clustering y mapa de calor	Cumplido
Correlaciones y distancias	Cumplido
Interpretación de similitudes, grupos y atípicos	Cumplido
Tres descubrimientos adicionales	Cumplido
LSTM enriquecido con catch22	Cumplido
Código reproducible y ejecutado	Cumplido

Referencias

- [1] Fulcher, B. D., Little, M. A. y Jones, N. S. (2013). *Highly comparative time-series analysis: the empirical structure of time series and their methods*. Journal of the Royal Society Interface, 10, 20130048.
- [2] Hochreiter, S. y Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, 9(8), 1735–1780.
- [3] Hyndman, R. J. y Athanasopoulos, G. *Forecasting: Principles and Practice*. <https://otexts.com/fpp3/>
- [4] Lubba, C. H. et al. (2019). *catch22: CAnonical Time-series CHaracteristics*. Data Mining and Knowledge Discovery, 33, 1821–1852.
- [5] Dynamics and Neural Systems Group. *pycatch22*. [Repositorio oficial de pycatch22](#).
- [6] Universidad del Valle de Guatemala (2026). *Laboratorio 2. Deep Learning. Series de Tiempo*.

Nota académica. La base y los resultados son de uso académico. Las predicciones no constituyen cifras oficiales ni sustituyen los procesos institucionales de validación.